

Basi di Dati 04/09/2012

1. (15 punti) Sia dato il seguente schema relazionale relativo ai corsi offerti da un'università e agli studenti che li frequentano:

Corso (Codice_corso, Anno, Titolo, Crediti)
Frequenza (Matricola_studente, Codice_corso, Voto)

Un **Corso** è identificato da un **Codice_corso**, ha un **Titolo** (e.g., 'Basi di Dati'), si svolge in un **Anno** accademico (e.g., '2011/2012') ed assegna agli studenti che lo superano un certo numero di **Crediti**. La relazione **Frequenza** memorizza le **Matricola_studente** degli studenti che frequentano o hanno frequentato un corso e, per coloro che lo hanno superato, il **Voto**. Il voto è NULL se il corso è ancora da superare.

- (a) Formulare in SQL la query per elencare le matricole degli studenti che hanno frequentato (quest'anno o in passato, non considerando il voto) entrambi i corsi **Basi di Dati** e **Sistemi Informativi**.
 - (b) Formulare in SQL la query per elencare matricola, media dei voti e numero di esami superati per ciascun studente che ha acquisito almeno 180 crediti (i.e., laureando), in ordine di matricola.
 - (c) Formulare in SQL la query per trovare anno, titolo e codice del corso frequentato dal minor numero di studenti in assoluto.
 - (d) Scrivere il comando SQL per assegnare il voto 18 allo studente con matricola 123456 che frequenta (i.e., esiste già tupla in **Frequenza**) il corso **Basi di Dati** anno accademico 2011/2012.
 - (e) Esprimere in algebra relazionale estesa le interrogazioni (a) e (b), senza obbligo di riportare il procedimento di conversione seguito.
2. (5 punti) Un docente universitario desidera creare un database per tenere traccia dei propri studenti e delle attività didattiche svolte.

Il docente insegna più corsi, di tipo triennale o specialistico, ciascuno identificato da titolo ed anno (e.g., 'Basi di Dati', '2011/2012'). Relativamente a tali corsi, il docente vuole tener traccia degli studenti che li frequentano, ognuno caratterizzato da matricola univoca, nome, cognome, ed eventuali note a cura del docente che influiscono sul voto.

Nell'ambito di un corso, il docente vuole registrare le attività didattiche svolte, che comprendono lezioni, ricevimento studenti e appelli d'esame.

Ciascuna delle tre attività è caratterizzata da corso di afferenza, durata, data e luogo di svolgimento (e.g., aula o ufficio docente). Per una lezione si memorizza anche l'argomento trattato. Per un ricevimento si tiene traccia dello studente che lo ha richiesto. Per un appello, infine, si memorizza la forma di esame (scritto o orale) e gli studenti iscritti, specificando per ognuno se era presente ed il punteggio ottenuto.

- (a) Produrre il modello E/R completo di entità, attributi, relazioni, molteplicità e chiavi.
 - (b) Tradurre il modello E/R in schema relazionale, con indicazione delle chiavi primarie.
3. (2 punti) Indicare se i seguenti programmi per le transazioni T1, T2, T3 sono conflict serializable. In caso affermativo, enumerare tutte le corrette esecuzioni seriali equivalenti.
- (a) r2(C) w1(B) r3(C) w1(A) w3(A) w2(C) r2(B)
 - (b) r2(C) w1(B) r2(C) w1(A) w3(A) r3(C) r2(B)
4. (3 punti) Sia data la relazione R(A,B), con $B(R) = 100$ e $M = 51$ blocchi di memoria principale (RAM) disponibili.
- (a) Descrivere un algoritmo per la valutazione di $\delta(R)$.
 - (b) Calcolare il numero di operazioni di I/O richieste dall'algoritmo.
5. (5 punti) Siano date le tre relazioni R(A,B), S(B,C), T(C,D), con:

$$\begin{array}{llll} T(R) &= 5 & V(R, B) &= 50 \\ T(S) &= 50 & V(S, B) &= 20 & V(S, C) &= 30 \\ T(T) &= 500 & V(T, C) &= 50 \end{array}$$

- (a) Descrivere il significato del parametro $V(R, B)$.
- (b) Indicare il modo migliore per valutare $R \bowtie S \bowtie T$.
- (c) Indicare il modo migliore per valutare

$$\text{i. } \sigma_{A=3 \wedge B>5}(R) \qquad \text{ii. } \sigma_{A=3 \vee B>5}(R)$$

ipotizzando:

$$\begin{array}{lll} T(R) = 10000 & V(R, A) = 1000 & \text{non-clustering index su A} \\ B(R) = 1000 & V(R, B) = 500 & \text{clustering index su B} \end{array}$$

Soluzioni

1. Soluzioni singoli quesiti:

(a) (SELECT Matricola_studente
FROM Corso NATURAL JOIN Frequenza
WHERE Titolo = 'Basi di Dati')
INTERSECT
(SELECT Matricola_studente
FROM Corso NATURAL JOIN Frequenza
WHERE Titolo = 'Sistemi Informativi')

oppure

```
SELECT DISTINCT S1.Matricola_studente
FROM   Corso C1, Frequenza F1, Corso C2, Frequenza F2
WHERE  C1.Codice_corso = F1.Codice_corso AND
       C2.Codice_corso = F2.Codice_corso AND
       C1.Titolo = 'Basi di Dati' AND
       C2.Titolo = 'Sistemi Informativi' AND
       F1.Matricola_studente = F2.Matricola_studente
```

(b) SELECT Matricola_studente,
AVG(Voto) AS Media, COUNT(*) AS Num_corsi
FROM Corso NATURAL JOIN Frequenza
WHERE Voto IS NOT NULL
GROUP BY Matricola_studente
HAVING SUM(Crediti) >= 180
ORDER BY Matricola_studente

(c) SELECT Codice_corso, Anno, Titolo
FROM Corso NATURAL JOIN Frequenza
GROUP BY Codice_corso, Anno, Titolo
HAVING COUNT(*) <= ALL
(SELECT COUNT(*)
FROM Frequenza
GROUP BY Codice_corso)

oppure

```
WITH Statistiche (Codice_corso, Num_studenti) AS
( SELECT Codice_corso, COUNT(*) AS Num_studenti
FROM   Corso NATURAL JOIN Frequenza
GROUP BY Codice_corso )
```


```

SELECT Codice_corso, Anno, Titolo
FROM   Corso NATURAL JOIN Statistiche
WHERE  Num_studenti = ( SELECT MIN(Num_studenti)
                        FROM   Statistiche )

```


(d) UPDATE Frequenza
 SET Voto = 18
 WHERE Matricola_studente = '123456' AND
 Codice_corso =
 (SELECT Codice_corso
 FROM Corso
 WHERE Anno = '2011/2012' AND
 Titolo = 'Basi di Dati')

(e) Espressioni algebra relazionale query (a) e (b) in ordine:



2. Di seguito le soluzioni dei singoli quesiti:

(a) Diagramma E/R:



(b) Schema relazionale:

```

Corso      (Titolo, Anno, Tipo)
Studente   (Matricola, Nome, Cognome, Note)
Frequenza  (Matricola_studente, Titolo_corso, Anno_corso)
Ricevimento (Codice, Titolo_corso, Anno_corso, Data,
             Luogo, Durata)
Appello    (Codice, Titolo_corso, Anno_corso, Data,
             Luogo, Durata, Forma)
Lezione    (Codice, Titolo_corso, Anno_corso, Data,
             Luogo, Durata, Argomento)
Richiesta  (Matricola_studente, Codice_ricevimento)
Iscrizione (Matricola_studente, Codice_appello,
             Punteggio, Presenza)
  
```

3. (a) Il programma è conflict serializable. Le dipendenze sono: T1 precede T3 causa $w1(A)w3(A)$; T1 precede T2 causa $w1(B)r2(B)$; T3 precede T2 causa $r3(C)w2(C)$. Non ci sono cicli e una corretta esecuzione seriale equivalente è T1, T3, T2.
- (b) Il programma è conflict serializable. Le dipendenze sono: T1 precede T2 causa $w1(B)r2(B)$; T1 precede T3 causa $w1(A)w3(A)$. Non ci sono cicli e due esecuzioni seriali equivalenti sono (1) T1, T2, T3 e (2) T1, T3, T2.
4. (a) Occorre usare un algoritmo a due passi, in quanto $B(R) > M - 1$. Due possibili algoritmi per l'eliminazione dei duplicati sono l'algoritmo a due passi basato su sorting (sezione 15.4.2 libro di testo) e l'algoritmo a due passi basato su hashing (sezione 15.5.2 libro di testo). Entrambi sono applicabili in quanto $B(R) < M^2$.

- (b) Con entrambi gli algoritmi a due passi menzionati, il costo è $3 \times B(R)$ (vedere libro).
5. (a) Stima del numero di valori distinti dell'attributo B nella relazione R.

(b) Stima risultati intermedi nei tre possibili ordinamenti del join:

- $(R \bowtie S) \bowtie T \longrightarrow T(R \bowtie S) = T(R) \times T(S)/V(R, B) = 5 \times 50/50 = 5$
- $R \bowtie (S \bowtie T) \longrightarrow T(S \bowtie T) = T(S) \times T(T)/V(T, C) = 50 \times 500/50 = 500$
- $(R \bowtie T) \bowtie S \longrightarrow T(R \bowtie T) = T(R) \times T(T) = 5 \times 500 = 2500$

La prima alternativa produce il minor numero di tuple intermedie, quindi è preferibile.

(c) La prima espressione $\sigma_{A=3 \wedge B>5}(R)$ si può valutare in tre modi:

- senza decomporre la condizione e usando table scan, costo $B(R) = 1000$;
- decomponendo come $\sigma_{A=3}(\sigma_{B>5}(R))$ e usando l'indice su B, costo $B(R)/3 = 334$;
- decomponendo come $\sigma_{B>5}(\sigma_{A=3}(R))$ e usando l'indice su A, costo $T(R)/V(R, A) = 10$.

La terza alternativa risulta più conveniente.

La seconda espressione $\sigma_{A=3 \vee B>5}(R)$ si può valutare in due modi:

- senza decomporre la condizione e usando table scan, costo $B(R) = 1000$;
- decomponendo come $\sigma_{A=3}(R) \cup \sigma_{B>5}(R)$ e usando entrambi gli indici su A e B, costo $B(R)/3 + T(R)/V(R, A) = 344$.

La seconda alternativa risulta più conveniente.