

## Basi di Dati 10/07/2012

1. (15 punti) Sia dato il seguente schema relazionale relativo ad una collezione di album musicali:

**Artista** (Nome\_artista, Nazione, Genere)  
**Album** (Nome\_album, Nome\_artista, Anno)  
**Canzone** (Nome\_canzone, Nome\_album, Durata)

Gli artisti (band o cantautori) sono identificati da un **Nome\_artista** e hanno una **Nazione** di provenienza ed un **Genere** musicale. Gli album sono caratterizzati da **Nome\_album** univoco, **Nome\_artista** autore dell'album e **Anno** di rilascio. Le canzoni sono identificate da **Nome\_canzone** e **Nome\_album** di appartenenza e hanno una **Durata** (**Float**) in minuti.

- (a) Formulare in SQL la query per elencare i nomi degli artisti italiani che hanno rilasciato due album in anni consecutivi almeno una volta nella loro carriera.
  - (b) Formulare in SQL la query per elencare, per ogni album del 2010 di almeno 10 canzoni, i nomi di album e artista e la durata totale.
  - (c) Formulare in SQL la query per trovare il nome dell'artista **ROCK** autore del maggior numero di album rilasciati a partire dal 1980.
  - (d) Scrivere il comando SQL per creare la tabella **Performance** per memorizzare **Luogo** e **Data** in cui un artista ha suonato una canzone presa da un suo album; artista, album e canzone sono codificati con i rispettivi nomi presi dalle rispettive tabelle. Definire i vincoli di chiave primaria e di integrità referenziale, ipotizzando che una canzone sia suonata al più una volta in uno stesso giorno.
  - (e) Esprimere in algebra relazionale estesa le interrogazioni (a) e (b), senza obbligo di riportare il procedimento di conversione seguito.
2. (5 punti) Una catena di librerie desidera creare un database per gestire gli acquisti di libri da parte dei clienti, effettuati online o in negozio.  
I libri hanno codice ISBN univoco, nome, autore, editore e prezzo.  
I clienti sono identificati dal codice della tessera di fidelizzazione; per essi sono noti nome, cognome, indirizzo e password per l'accesso online.  
Un acquisto è eseguito da un cliente in una certa data e ora e riguarda uno o più libri; di un libro sono acquistabili più copie. Per gli acquisti

in negozio si memorizza la città del negozio. Per gli acquisti online si memorizza la modalità di pagamento (e.g., bonifico); inoltre, per l'acquirente è possibile richiedere la spedizione dei libri acquistati in pacco regalo ad un altro cliente, di cui si vuol tenere traccia.

- (a) Produrre il modello E/R completo di entità, attributi, relazioni.
- (b) Tradurre il modello E/R in schema relazionale.

3. (2 punti) Per ciascuno dei seguenti programmi, indicare se è conflict serializable e, se sì, scrivere una corretta esecuzione seriale equivalente.

- (a)  $r3(C) \quad r1(A) \quad w3(B) \quad r1(D) \quad w2(A) \quad w2(B) \quad w1(C) \quad r3(D)$
- (b)  $r3(C) \quad r1(A) \quad w2(B) \quad r1(D) \quad w2(A) \quad r3(B) \quad w2(C) \quad r3(D)$

4. (4 punti) Siano date le due relazioni  $R(A,B)$  e  $S(B,C)$  e la query  $Q$ :

```
SELECT DISTINCT C
FROM   R NATURAL JOIN S
WHERE  B = 2
```

- (a) Scrivere tre espressioni di algebra relazionale estesa equivalenti a  $Q$ , riportando le relative rappresentazioni ad albero e senza obbligo di riportare il procedimento di conversione seguito.
- (b) Analizzare il costo per valutare ciascuna espressione e decidere quale è la migliore, dati:

$$T(R) = 20000 \quad T(S) = 2000 \quad V(R, B) = 10 \quad V(S, B) = 5$$

5. (4 punti) Siano date le tre relazioni  $R(A,B)$ ,  $S(B,C)$  e  $U(C,D)$ .

- (a) Indicare l'ordinamento migliore per il join  $R \bowtie S \bowtie U$ , dati:

$$\begin{array}{llll} T(R) = 500 & T(U) = 8000 & T(S) = 1000 & \\ V(R, B) = 8 & V(U, C) = 40 & V(S, B) = 40 & V(S, C) = 40 \end{array}$$

- (b) Indicare il modo migliore per valutare  $\sigma_{A=1 \text{ or } B=2}(R)$ , dati:

$$\begin{array}{lll} T(R) = 1000 & V(R, A) = 50 & \text{clustering index su A} \\ B(R) = 100 & V(R, B) = 200 & \text{non-clustering index su B} \end{array}$$

## Soluzioni

### 1. Soluzioni singoli quesiti:

```
(a) SELECT DISTINCT T.Nome_artista
     FROM   Artista T JOIN Album AS A1
           ON T.Nome_artista = A1.Nome_artista
           JOIN Album AS A2
           ON T.Nome_artista = A2.Nome_artista
     WHERE  T.Nazione = 'Italia' AND
           ( A2.Anno = A1.Anno - 1 OR
             A2.Anno = A1.Anno + 1 )
```

```
(b) SELECT  Nome_album, Nome_artista,
            SUM(Durata) AS Durata_totale
     FROM    Album NATURAL JOIN Canzone
     WHERE   Anno = 2010
     GROUP BY Nome_album, Nome_artista
     HAVING  COUNT(*) >= 10
```

```
(c) WITH Discografia (Nome_artista, Numero_album) AS
     ( SELECT  Nome_artista, COUNT(*) AS Numero_album
       FROM    Artista NATURAL JOIN Album
       WHERE   Genere = 'ROCK' AND Anno >= 1980
       GROUP BY Nome_artista )
     SELECT Nome_artista
     FROM   Discografia
     WHERE  Numero_album = ( SELECT MAX(Numero_album)
                             FROM   Discografia )
```

*oppure*



```
SELECT  Nome_artista
FROM    Artista NATURAL JOIN Album
WHERE   Genere = 'ROCK' AND Anno >= 1980
GROUP BY Nome_artista
HAVING  COUNT(*) >= ALL
       ( SELECT  COUNT(*)
         FROM    Artista NATURAL JOIN Album
         WHERE   Genere = 'ROCK' AND Anno >= 1980
         GROUP BY Nome_artista )
```

```

(d) CREATE TABLE Performance (
    Nome_artista VARCHAR(40)
        REFERENCES Artista(Nome_artista)
        ON UPDATE CASCADE ON DELETE CASCADE,
    Nome_album VARCHAR(40),
    Nome_canzone VARCHAR(40),
    Data DATE,
    Luogo VARCHAR(40) NOT NULL,
    PRIMARY KEY (Nome_artista, Nome_album,
        Nome_canzone, Data),
    FOREIGN KEY (Nome_album, Nome_canzone) REFERENCES
        Canzone (Nome_album, Nome_canzone)
        ON UPDATE CASCADE ON DELETE CASCADE
)


```

(e) Espressioni algebra relazionale query (a) e (b) in ordine:



2. Di seguito le soluzioni dei singoli quesiti:

(a) Diagramma E/R:




(b) Schema relazionale:

|              |                                                                                                        |
|--------------|--------------------------------------------------------------------------------------------------------|
| Libro        | (isbn, nome, autore, editore, prezzo)                                                                  |
| Cliente      | (codice_tessera, password, nome, cognome, indirizzo)                                                   |
| Acquisto     | (codice_cliente_acquirente, data, ora, tipo, città_negozio, modalità_pagamento, codice_cliente_regalo) |
| Composizione | (codice_cliente_acquirente, data, ora, isbn_libro, numero_copie)                                       |

In questo caso, è consigliabile introdurre una chiave sintetica (e.g., Codice\_acquisto) per Acquisto, in modo da usare due attributi in meno in Composizione (risparmiando così spazio).

3. (a) Il programma è conflict serializable. Le dipendenze sono: T3 precede T1 causa  $r3(C)w1(C)$ ; T1 precede T2 causa  $r1(A)w2(A)$ ; T3 precede T2 causa  $w3(B)w2(B)$ . Non ci sono cicli e una corretta esecuzione seriale equivalente è T3, T1, T2.
- (b) Il programma non è conflict serializable. Le dipendenze sono: T1 precede T2 causa  $r1(A)w2(A)$ ; T2 precede T3 causa  $w2(B)r3(B)$ ; T3 precede T2 causa  $r3(C)w2(C)$ . Tra T2 e T3 sussiste quindi un ciclo.

4. (a) Tre possibili espressioni algebriche per  $Q$  sono le seguenti:



- (b) Si valuta il numero max di risultati intermedi per ogni espressione:

- la prima espressione produce  $T(R) \times T(S) / V(R, B) = 20000 \times 2000 / 10 = 4000000$  tuple dopo il join, poi ridotte da successiva selezione, proiezione e rimozione duplicati;
- nella seconda espressione, gli operandi del join hanno cardinalità  $T(R) / V(R, B) = 20000 / 10 = 2000$  e  $T(S) / V(S, B) = 2000 / 5 = 400$  tuple, mentre il join diventa cartesiano ( $B$  ha sempre lo stesso valore, 2) e produce  $2000 \times 400 = 800000$  tuple, poi ridotte da successiva proiezione e rimozione duplicati;
- nella terza espressione, il primo operando del join ha cardinalità massima 1 (se c'è qualche tupla di  $R$  con  $B = 2$ ), mentre il secondo operando ha cardinalità minore di 400 (dipende da  $V(S, C)$ , ignoto); il join (cartesiano) produce al più  $400 \times 1 = 400$  tuple intermedie, pari al numero di tuple finali.

Risulta quindi più efficiente la terza espressione, in quanto produce al più 400 tuple intermedie (vs 4000000 e 800000 tuple).

5. (a) alternativa  $(R \bowtie S) \bowtie U$ :

- $T(R \bowtie S) = T(R) \times T(S) / V(S, B) = 500 \times 1000 / 40 = 12500$
- $T((R \bowtie S) \bowtie U) = T(R \bowtie S) \times T(U) / V(U, C) = 12500 \times 8000 / 40 = 2500000$

alternativa  $R \bowtie (S \bowtie U)$ :

- $T(S \bowtie U) = T(S) \times T(U) / V(U, C) = 1000 \times 8000 / 40 = 200000$
- $T(R \bowtie (S \bowtie U)) = T(R) \times T(S \bowtie U) / V(S, B) = 500 \times 200000 / 40 = 2500000$

alternativa  $(R \bowtie U) \bowtie S$ :

- $T(R \bowtie U) = T(R) \times T(U) = 500 * 8000 = 4000000$
- $T((R \bowtie U) \bowtie S) = T(R \bowtie U) \times T(S) / (V(S, B) \times V(U, C)) = 4000000 \times 1000 / (40 \times 40) = 2500000$

Tutte e tre le alternative producono lo stesso numero di tuple, 2500000 (c.v.d.), tuttavia la prima –  $(R \bowtie S) \bowtie U$  – produce meno tuple intermedie –  $T(R \bowtie S) = 12500$  vs  $T(S \bowtie U) = 200000$  e  $T(R \bowtie U) = 4000000$  – ed è quindi preferibile.

(b) Sono possibili due alternative per valutare  $\sigma_{A=1}$  or  $\sigma_{B=2}(R)$ :

- table scan su R – il costo è  $B(R) = 100$
- $\sigma_{A=1}(R) \cup \sigma_{B=2}(R)$  – per valutare i due operandi non si può usare un table scan, in quanto il costo sarebbe uguale o maggiore a quello della prima alternativa; costi:  
 $\sigma_{A=1}(R)$  con indice su A:  $B(R)/V(R, A) = 100/50 = 2$   
 $\sigma_{B=2}(R)$  con indice su B:  $T(B)/V(R, B) = 1000/200 = 5$   
 $\sigma_{A=1}(R) \cup \sigma_{B=2}(R)$ :  $2+5 = 7$  (con almeno 7 blocchi memoria).

L'alternativa più conveniente è quindi la seconda, con uso di entrambi gli indici su A e B.